

08 · Neuronale Codes & Feed-Forward-Netze

Brain-Inspired Computing · Vorlesung 8 · ausführliche Zusammenfassung

1 · Wie kodieren Neuronen Information?

Neuronen können Information auf mehrere Weisen tragen. Die **Codes koexistieren** und schließen sich nicht aus. Man unterscheidet vier Grundtypen.

1.1 · Rate-Code

Information steckt in der **Feuerrate** (Spikes/s), gemittelt über ein Zeitfenster. - Klassisches Beispiel: **Tuning-Kurven** — die Rate eines V1-Neurons als Funktion der Reizorientierung (Hubel & Wiesel, 1968): maximale Antwort bei der **bevorzugten Orientierung**, Abfall zu beiden Seiten. - **Rezeptives Feld**: Region/Reizmuster, das ein Neuron „sieht“. Retinale Ganglienzellen haben **On-Center/Off-Surround** (oder umgekehrt): Ein Lichtpunkt im Zentrum erregt (On-Center), im Umfeld hemmt er. Gut modelliert durch **Difference of Gaussians (DoG)**. Diffuse (Ganzfeld-)Beleuchtung erregt kaum, weil Zentrum und Umfeld sich aufheben → **Kontrast-/Kantendetektion**. - **Nachteil**: niedrige zeitliche Auflösung — Mitteln braucht Zeit.

1.2 · Place-Code

Information steckt in **welches** Neuron feuert (Identität/Ort im Netz). - Beispiel: **Ortszellen (place cells)** im Hippocampus (O'Keefe; Nobelpreis 2014, mit Moser & Moser für **grid cells**). Jede Zelle feuert an einem bestimmten Ort im Raum → eine zuverlässige, topografische **Karte**.

1.3 · Temporal-Code

Information in der **präzisen relativen Zeit** der Spikes → **sehr hohe** Auflösung. - Beispiel: **Schallquellen-Lokalisation** über **Delay-Line + Koinzidenzdetektor** (Jeffress-Modell): interaurale Laufzeitdifferenzen werden im **µs-Bereich** ausgewertet (obwohl $\tau_m \sim \text{ms}$), Winkelauflösung $\sim 1-2^\circ$.

1.4 · Phase-Code

Information **relativ zu einem oszillatorischen Referenzsignal** (z. B. Theta-Rhythmus). - Beispiel: **Phase Precession** von Hippocampus-Ortszellen — der Feuerzeitpunkt relativ zur Theta-Oszillation kodiert die Position innerhalb des Feldes zusätzlich zur Rate.

Verweise: Folie L8 „Rate/Place/Temporal/Phase code“, „tuning curves“, „receptive fields (DoG)“, „sound localization“. Hubel & Wiesel 1968; Nobelpreis 2014. Literatur: Dayan & Abbott, Kap. 1-2 (neural code, tuning, receptive fields); Gerstner et al., *Neuronal Dynamics*, Kap. 7 & 12.

2 · Rate-basierte Netzwerkmodelle

Spikende Neuronen sind **rechenaufwändig** und **analytisch schwierig**. Man ersetzt sie daher durch **firing-rate units**: + analytisch handhabbar, – verliert spike-timing-Codes.

2.1 · Rate-based input integration (Herleitung)

Man ersetzt den präsynaptischen Spike-Train durch seinen Erwartungswert (die Rate $x_i(\tau)$). Der synaptische Strom eines exponentiellen CUBA-Kernels wird dann zur Faltung, deren Ableitung eine einfache **lineare DGL** ergibt:

$$\tau_{\text{syn}} \, dI/dt = -I + \tau_{\text{syn}} \, \mathbf{w} \cdot \mathbf{x} \Rightarrow \text{Steady state: } I = \tau_{\text{syn}} \, \mathbf{w} \cdot \mathbf{x}$$

Der Strom folgt der gewichteten Eingangssumme $\mathbf{w} \cdot \mathbf{x}$ also wie ein **Tiefpass** mit $\tau_{\text{syn}} \cdot w_i > 0$ = Erregung, $w_i < 0$ = Hemmung.

2.2 · Rate-based response & Aktivierungsfunktionen

Bei konstantem Input läuft die Ausgangsrate gegen $z \rightarrow \mathbf{F}(\mathbf{w} \cdot \mathbf{x})$; bei zeitvariablem Input folgt sie verzögert:

$$\tau \, dz/dt = -z + \mathbf{F}(\mathbf{w} \cdot \mathbf{x})$$

F(I) ist die **f-I-Kurve** (Rate über Input) — zugleich die **Aktivierungsfunktion** künstlicher Netze. Gängige Formen: **Softplus** $\log(1+e^I)$, **Sigmoid** $z_{\text{max}}/(1+e^{-I})$, **ReLU** $[I]_+ = \max(0, I)$, **Exponentiell** e^I .

2.3 · Rekurrentes Netz (Populationsdynamik)

Allgemein koppeln Feed-Forward-Input ($v_{ki}x_i$), Rückkopplung ($w_{kj}z_j$, Konvention $w_{\text{post,pre}}$) und ein Bias b_k :

$$\tau \, dz_k/dt = -z_k + \mathbf{F}\left(\sum_j w_{kj} z_j + \sum_i v_{ki} x_i + b_k\right)$$

Das ist die Grundgleichung eines **rekurrenten neuronalen Netzes** und die **Brücke** zu Perzeptron/Deep Learning (L11). Für $w_{kj} = 0$ erhält man ein reines **Feed-Forward-Netz**.

3 · Binäre Logik & Turing-Vollständigkeit (rate-based)

Mit **ReLU**-Units $[V_k + b_k]_+$ und binären Inputs $x_i \in \{L, H\}$ ($0 \leq L < H$) baut man stationäre Logik:

- **NOT(x)**: ein **einzelnes** Neuron, Gewicht -1 , Bias $H+L \rightarrow z = [-x + H + L]_+$ liefert H für $x=L$ und L für $x=H$.
- **NAND(x₁, x₂)**: ein **zweistufiges** Netz — x_1, x_2 mit Gewicht $+1$ auf z_1 (Bias $-(H+L)$), dann z_1 mit Gewicht -1 auf z_2 (Bias H). Die **Nichtlinearität** von $[\cdot]_+$ an z_1 ist entscheidend (nur für H, H bleibt $2H - (H+L) = H - L > 0$ übrig).

Warum das mächtig ist:

- **NAND ist funktional vollständig** — jede boolesche Funktion folgt aus NANDs, z. B. **NOT(x) = NAND(x, x)**; auch Addition und Multiplikation sind realisierbar.
- Daraus folgt: rate-basierte neuronale Netze können **jede CPU-Instruktion emulieren** → **Turing-vollständig**. „Rule-based“ (regelbasiertes) Rechnen ist also **möglich**, aber **nicht** der natürliche/effiziente Betriebsmodus des Gehirns (das rechnet eher verteilt, plastisch, analog).

4 · Winner-Takes-All (WTA) — Einstieg

Konkurrierende Neuronen/Populationen, die über eine **gemeinsame Hemmung** konkurrieren: Das am stärksten getriebene Neuron unterdrückt die anderen und „gewinnt“. Das realisiert **Selektion / Klassifikation** (die Ausgabe ist ein Place-Code: „welches Neuron gewinnt“). Dynamik, Phasenraum-Analyse und Stabilität folgen in **L9**.

Kernbotschaften L8: Vier Codes: **Rate** (Tuning-Kurven, receptive Felder/DoG, Kontrast), **Place** (Ortszellen), **Temporal** (Delay-Line + Koinzidenz, μ s-Präzision, Jeffress), **Phase** (rel. zu Oszillation). Rate-Modell: Input-Integration $\tau_{\text{syn}} \dot{I} = -I + \tau_{\text{syn}} \mathbf{w} \cdot \mathbf{x}$; Response $\tau \dot{z} = -z + F(\mathbf{w} \cdot \mathbf{x})$ mit Aktivierungsfunktion F (Softplus/Sigmoid/ReLU/exp); rekurrent $\tau \dot{z}_k = -z_k + F(\sum_{kj} w_{kj} z_j + \sum_{ki} v_{ki} x_i + b_k)$ = Brücke zu Deep Learning. ReLU-Logik: NOT = 1 Unit, NAND = 2-stufiges Netz; NAND funktional vollständig → Netze **Turing-vollständig** (aber nicht der natürliche Modus). WTA = Konkurrenz über gemeinsame Hemmung → Selektion (Details L9).

Multiple-Choice-Fragen (Lösungen in [Loesungen_MC.pdf](#))

MC 8.1 — Welcher Code nutzt die **Identität** des feuernenden Neurons?

1. Rate-Code
2. Place-Code

3. Temporal-Code
4. Phase-Code

MC 8.2 — Rezeptive Felder retinaler Ganglienzellen (On-Center) werden gut beschrieben durch ...

1. das Wiener-Chintschin-Theorem
2. eine reine Exponentialfunktion
3. eine einzelne Gaußkurve
4. Difference of Gaussians (DoG)

MC 8.3 — Warum sind rate-basierte neuronale Netze prinzipiell Turing-vollständig?

1. Weil ein kleines Rate-Netz NAND realisiert und NAND funktional vollständig ist.
2. Weil sie kontinuierliche Zeit nutzen.
3. Weil sie eine Refraktärzeit besitzen.
4. Weil sie Poisson-Statistik haben.

MC 8.4 — Die Schallquellen-Lokalisation über Delay-Line + Koinzidenzdetektor ist ein Beispiel für ...

1. Temporal-Code
2. Rate-Code
3. reine Ratenkodierung
4. Place-Code

MC 8.5 — Die rate-basierte Antwortfunktion $v_{\text{out}} = F(\sum w_j v_j)$...

1. gilt nur für einen einzelnen Spike.
2. ist unabhängig von den Gewichten.
3. verbindet Spike-Modelle mit abstrakten Raten-/Perzeptron-Netzen; F ist die Aktivierungsfunktion.
4. beschreibt die ISI-Verteilung.

MC 8.6 — Wie realisiert man NOT(x) allein aus NAND?

1. $\text{NAND}(x, 0)$
2. $\text{NAND}(x, 1)$
3. gar nicht — dafür braucht man OR

4. NAND(x, x)

MC 8.7 — Warum antwortet eine On-Center-Ganglienzelle kaum auf **diffuse** (Ganzfeld-)Beleuchtung?

1. weil sie ein Phase-Code-Neuron ist.
2. weil die Refraktärzeit zu lang ist.
3. weil erregendes Zentrum und hemmendes Umfeld sich gegenseitig aufheben.
4. weil sie nur Farbe kodiert.

MC 8.8 — Welcher Code hat die **höchste zeitliche Auflösung**?

1. Place-Code
2. alle gleich
3. Rate-Code
4. Temporal-Code

MC 8.9 — Die **Phase Precession** von Ortszellen ist ein Beispiel für ...

1. rein zufälliges Feuern
2. Place-Code
3. Phase-Code
4. Rate-Code

MC 8.10 — Welche Aussage über regelbasiertes (rule-based) Rechnen mit Neuronen ist korrekt?

1. Es benötigt zwingend elektrische Synapsen.
2. Es ist prinzipiell möglich (Turing-vollständig), aber nicht der natürliche/effiziente Modus des Gehirns.
3. Es ist unmöglich mit LIF-Neuronen.
4. Es funktioniert nur mit Hodgkin-Huxley-Neuronen.

MC 8.11 — In der rate-basierten ReLU-Logik der Vorlesung gilt ...

1. NOT braucht zwei Schichten, NAND nur eine.
2. NOT = ein einzelnes Neuron (Gewicht -1 , Bias $H+L$); NAND = zweistufiges Netz (Nichtlinearität an z_1).
3. weder NOT noch NAND sind realisierbar.

4. NAND ist linear und braucht keine Aktivierungsfunktion.

MC 8.12 — Die Populationsdynamik $\tau \frac{dz_k}{dt} = -z_k + F(\sum w_{kj}z_j + \sum v_{ki}x_i + b_k) \dots$

1. beschreibt ein rekurrentes Rate-Netz; F ist die Aktivierungsfunktion, b_k der Bias.
2. gilt nur für einen einzelnen Spike.
3. ist die ISI-Verteilung.
4. enthält keine Rückkopplung.

Freitext-Fragen (zum Besprechen)

1. Stelle die vier Codes (Rate, Place, Temporal, Phase) mit je einem biologischen Beispiel gegenüber. Welcher hat die höchste zeitliche Auflösung und warum ist das trotz ms-Membranzeitkonstante möglich?
2. Erkläre das rezeptive Feld einer On-Center-Ganglienzelle und wie DoG es modelliert. Warum ist das ein Kanten-/Kontrastdetektor?
3. Zeige konstruktiv, wie man aus einem NAND-fähigen LIF-Neuron NOT, AND und OR aufbaut. Was folgt daraus für die Rechenmächtigkeit von Netzen?
4. Wie hängt die rate-basierte Antwortfunktion mit dem Perzeptron/Deep Learning (L11) zusammen? Worin unterscheidet sie sich vom spike-basierten Modell?
5. Erkläre das Jeffress-Modell (Delay-Line + Koinzidenz) für die Schall-Lokalisation. Wieso ist μs -Präzision trotz $\text{ms}-\tau_m$ erreichbar?
6. Diskutiere: Warum ist Turing-Vollständigkeit ein interessantes, aber nur begrenzt nützliches Argument für das Verständnis des Gehirns?