

08 · Neuronale Codes & Feed-Forward-Netze

Brain-Inspired Computing · Vorlesung 8 · ausführliche Zusammenfassung

1 · Wie kodieren Neuronen Information?

Neuronen können Information auf mehrere Weisen tragen. Die **Codes koexistieren** und schließen sich nicht aus. Man unterscheidet vier Grundtypen.

1.1 · Rate-Code

Information steckt in der **Feuerrate** (Spikes/s), gemittelt über ein Zeitfenster. - Klassisches Beispiel: **Tuning-Kurven** — die Rate eines V1-Neurons als Funktion der Reizorientierung (Hubel & Wiesel, 1968): maximale Antwort bei der **bevorzugten Orientierung**, Abfall zu beiden Seiten. - **Rezeptives Feld**: Region/Reizmuster, das ein Neuron „sieht“. Retinale Ganglienzellen haben **On-Center/Off-Surround** (oder umgekehrt): Ein Lichtpunkt im Zentrum erregt (On-Center), im Umfeld hemmt er. Gut modelliert durch **Difference of Gaussians (DoG)**. Diffuse (Ganzfeld-)Beleuchtung erregt kaum, weil Zentrum und Umfeld sich aufheben → **Kontrast-/Kantendetektion**. - **Nachteil**: niedrige zeitliche Auflösung — Mitteln braucht Zeit.

1.2 · Place-Code

Information steckt in **welches** Neuron feuert (Identität/Ort im Netz). - Beispiel: **Ortszellen (place cells)** im Hippocampus (O'Keefe; Nobelpreis 2014, mit Moser & Moser für **grid cells**). Jede Zelle feuert an einem bestimmten Ort im Raum → eine zuverlässige, topografische **Karte**.

1.3 · Temporal-Code

Information in der **präzisen relativen Zeit** der Spikes → **sehr hohe** Auflösung. - Beispiel: **Schallquellen-Lokalisation** über **Delay-Line + Koinzidenzdetektor** (Jeffress-Modell): interaurale Laufzeitdifferenzen werden im **µs-Bereich** ausgewertet (obwohl $\tau_m \sim \text{ms}$), Winkelauflösung $\sim 1-2^\circ$.

1.4 · Phase-Code

Information **relativ zu einem oszillatorischen Referenzsignal** (z. B. Theta-Rhythmus). - Beispiel: **Phase Precession** von Hippocampus-Ortszellen — der Feuerzeitpunkt relativ zur Theta-Oszillation kodiert die Position innerhalb des Feldes zusätzlich zur Rate.

Verweise: Folie L8 „Rate/Place/Temporal/Phase code“, „tuning curves“, „receptive fields (DoG)“, „sound localization“. Hubel & Wiesel 1968; Nobelpreis 2014. Literatur: Dayan & Abbott, Kap. 1-2 (neural code, tuning, receptive fields); Gerstner et al., *Neuronal Dynamics*, Kap. 7 & 12.

2 · Rate-basierte Antwortfunktion

Für konstanten Input mit Rate v_{in} ergibt sich eine stationäre Ausgangsrate über eine **Antwort-/Aktivierungsfunktion F**:

$$v_{out} = F\left(\sum_j w_j v_j\right)$$

Bei zeitlich veränderlichem Input folgt der Ausgang $F(t)$ **verzögert** (die Membran ist ein Tiefpass mit Zeitkonstante τ , s. L9). Diese Gleichung ist die **Brücke** zwischen spike-basierten Modellen und **abstrakten Raten-Netzen** (Perzeptron/Deep Learning, L11): w_j sind die synaptischen Gewichte, F entspricht der Aktivierungsfunktion (z. B. sigmoid, ReLU).

3 · Feed-Forward-Netze aus LIF-Neuronen

Ein LIF-Neuron mit exzitatorischen (COBA, L5) Synapsen bildet einen präsynaptischen Spike-Train linear-gewichtet ab ($\sum w_j x_j$) und erzeugt bei Schwellenüberschreitung Ausgabespikes. Mit passenden Gewichten und Schwellen lassen sich so **logische Funktionen** realisieren — das Neuron wirkt als **Schwellenlogik-Gatter**.

4 · Turing-Vollständigkeit / Rule-based Computing

Ein einzelnes LIF-Neuron kann ein **NAND**-Gatter realisieren (z. B. über „leak over threshold“ mit geeigneter Gewichtung/Schwelle):

$$\text{NAND}(a, b) = \neg(a \wedge b): \text{ feuert immer, außer wenn } a \text{ UND } b \text{ beide aktiv sind}$$

Warum das mächtig ist: - **NAND ist ein universelles Gatter** — jede boolesche Funktion lässt sich allein aus NANDs aufbauen, z. B. **NOT(x) = NAND(x, x)**, **AND(a,b) = NOT(NAND(a,b))** usw. - Mit Rückkopplung/Speicher folgt: **Neuronen-Netze sind Turing-vollständig** — im Prinzip so mächtig wie jede CPU. „Rule-based“ (regelbasiertes) Rechnen mit Neuronen ist also **möglich** — aber es ist **nicht** der natürliche/effiziente Betriebsmodus des Gehirns (das nutzt eher verteilte, plastische, analoge Berechnung).

5 · Winner-Takes-All (WTA) — Einstieg

Konkurrierende Neuronen mit **lateralen Hemmung**: Das am stärksten getriebene Neuron unterdrückt die anderen und „gewinnt“. Das realisiert **Selektion** /

Klassifikation (die Ausgabe ist ein Place-Code: „welches Neuron gewinnt“). Dynamik, Phasenraum-Analyse und Stabilität folgen in **L9**.

Kernbotschaften L8: Vier Codes: **Rate** (Tuning-Kurven, rezeptive Felder/DoG, Kontrast), **Place** (Ortszellen), **Temporal** (Delay-Line + Koinzidenz, μ s-Präzision), **Phase** (rel. zu Oszillation). Rate-Antwort $v_{\text{out}} = F(\sum w_j v_j)$ = Brücke zu Perzeptron/Deep Learning. LIF realisiert NAND → NAND universell → Netze **Turing-vollständig** (aber nicht der natürliche Modus). WTA = laterale Hemmung → Selektion (Details L9).

Multiple-Choice-Fragen (Lösungen in [Loesungen_MC.pdf](#))

MC 8.1 — Welcher Code nutzt die **Identität** des feuernenden Neurons?

1. Rate-Code
2. Place-Code
3. Temporal-Code
4. Phase-Code

MC 8.2 — Rezeptive Felder retinaler Ganglienzellen (On-Center) werden gut beschrieben durch ...

1. das Wiener-Chintschin-Theorem
2. eine reine Exponentialfunktion
3. eine einzelne Gaußkurve
4. Difference of Gaussians (DoG)

MC 8.3 — Warum sind Netze aus LIF-Neuronen prinzipiell Turing-vollständig?

1. Weil ein LIF ein NAND realisieren kann und NAND ein universelles Gatter ist.
2. Weil sie kontinuierliche Zeit nutzen.
3. Weil sie eine Refraktärzeit besitzen.
4. Weil sie Poisson-Statistik haben.

MC 8.4 — Die Schallquellen-Lokalisation über Delay-Line + Koinzidenzdetektor ist ein Beispiel für ...

1. Temporal-Code
2. Rate-Code
3. reine Ratenkodierung

4. Place-Code

MC 8.5 — Die rate-basierte Antwortfunktion $v_{\text{out}} = F(\sum w_j v_j)$...

1. gilt nur für einen einzelnen Spike.
2. ist unabhängig von den Gewichten.
3. verbindet Spike-Modelle mit abstrakten Raten-/Perzeptron-Netzen; F ist die Aktivierungsfunktion.
4. beschreibt die ISI-Verteilung.

MC 8.6 — Wie realisiert man NOT(x) allein aus NAND?

1. NAND(x, 0)
2. NAND(x, 1)
3. gar nicht — dafür braucht man OR
4. NAND(x, x)

MC 8.7 — Warum antwortet eine On-Center-Ganglienzelle kaum auf **diffuse** (Ganzfeld-)Beleuchtung?

1. weil sie ein Phase-Code-Neuron ist.
2. weil die Refraktärzeit zu lang ist.
3. weil erregendes Zentrum und hemmendes Umfeld sich gegenseitig aufheben.
4. weil sie nur Farbe kodiert.

MC 8.8 — Welcher Code hat die **höchste zeitliche Auflösung**?

1. Place-Code
2. alle gleich
3. Rate-Code
4. Temporal-Code

MC 8.9 — Die **Phase Precession** von Ortszellen ist ein Beispiel für ...

1. rein zufälliges Feuern
2. Place-Code
3. Phase-Code
4. Rate-Code

MC 8.10 — Welche Aussage über regelbasiertes (rule-based) Rechnen mit Neuronen ist korrekt?

1. Es benötigt zwingend elektrische Synapsen.
2. Es ist prinzipiell möglich (Turing-vollständig), aber nicht der natürliche/effiziente Modus des Gehirns.
3. Es ist unmöglich mit LIF-Neuronen.
4. Es funktioniert nur mit Hodgkin-Huxley-Neuronen.

Freitext-Fragen (zum Besprechen)

1. Stelle die vier Codes (Rate, Place, Temporal, Phase) mit je einem biologischen Beispiel gegenüber. Welcher hat die höchste zeitliche Auflösung und warum ist das trotz ms-Membranzeitkonstante möglich?
2. Erkläre das rezeptive Feld einer On-Center-Ganglienzelle und wie DoG es modelliert. Warum ist das ein Kanten-/Kontrastdetektor?
3. Zeige konstruktiv, wie man aus einem NAND-fähigen LIF-Neuron NOT, AND und OR aufbaut. Was folgt daraus für die Rechenmächtigkeit von Netzen?
4. Wie hängt die rate-basierte Antwortfunktion mit dem Perzeptron/Deep Learning (L11) zusammen? Worin unterscheidet sie sich vom spike-basierten Modell?
5. Erkläre das Jeffress-Modell (Delay-Line + Koinzidenz) für die Schall-Lokalisation. Wieso ist μs -Präzision trotz $\text{ms}-\tau_m$ erreichbar?
6. Diskutiere: Warum ist Turing-Vollständigkeit ein interessantes, aber nur begrenzt nützliches Argument für das Verständnis des Gehirns?