

09 · Tuning-Kurven, Netzdynamik & Winner-Takes-All

Brain-Inspired Computing · Vorlesung 9 · ausführliche Zusammenfassung

1 · Tuning-Kurven: das Neuron als Template-Matcher

Ein rate-basiertes Neuron z_k erhält den Input $\mathbf{x} = (x_1, \dots, x_N)$ über die Gewichte $\mathbf{V}_k = (V_{k1}, \dots, V_{kN})$. Für **statischen** Input strebt es gegen

$$z_k \rightarrow F(\mathbf{V}_k \cdot \mathbf{x}) \quad (t \rightarrow \infty)$$

Frage: Auf welchen Stimulus $\mathbf{x}^*$ reagiert das Neuron am stärksten? Weil $F(\cdot)$ streng monoton steigt, maximiert man einfach das Skalarprodukt:

$$\mathbf{x}^* = \operatorname{argmax}_{\mathbf{x}} \mathbf{V}_k \cdot \mathbf{x} = \operatorname{argmax}_{\mathbf{x}} \|\mathbf{x}\| \|\mathbf{V}_k\| \cos \angle(\mathbf{V}_k, \mathbf{x})$$

Bei **fester Reizstärke** ($\|\mathbf{x}\| = \text{const}$) ist das Skalarprodukt maximal, wenn der Input **parallel** zum Gewichtsvektor liegt:

$$\mathbf{x}^* \parallel \mathbf{V}_k$$

Man liest $\mathbf{V}_k$ daher als **räumlichen Kernel** bzw. **bevorzugtes Eingangsmuster**: „Neuron k ist auf das Muster $\mathbf{x} \parallel \mathbf{V}_k$ getunt.“ Die Tuning-Kurve ist damit nichts anderes als **Template-Matching per Skalarprodukt** — sie misst, wie gut der Input zum gespeicherten Muster passt.

Verweise: Folie L9 „tuning curve“, „temporal dynamics / low-pass filter / Green’s function“, „competing excitatory populations“, „phase plane analysis“, „Winner-Take-All“, „multiple WTA populations“. Literatur: Dayan & Abbott, Kap. 7 (network/firing-rate models); Gerstner et al., *Neuronal Dynamics*, Kap. 15–16 (rate models, competition, attractors).

2 · Zeitliche Dynamik in Feed-forward-Netzen

Für **Feed-forward-Netze** (keine Rückkopplungsschleifen) ist die Dynamik einfach: Jedes Neuron ist ein **Tiefpassfilter** seines Inputs $V_k(t)$:

$$(\partial_t + 1/\tau_k) z_k = (1/\tau_k) \cdot F(V_k(t) + b_k) =: f_k(t)$$

Die Aktivität pflanzt sich Schicht für Schicht fort; formal über die **Green’sche Funktion** (Impulsantwort) $G(t) = \Theta(t) e^{-t/\tau_k}$:

$$z_k(t) = \int G(t-t') f_k(t') dt'$$

Ein Puls wird also in jeder Schicht per Tiefpass **geglättet**. Schaltet man **zwei** Exponential-Filter hintereinander ($x \rightarrow^V z_1 \rightarrow^W z_2$), ergibt sich — wie schon bei den synaptischen Kernen (L5) — eine **Difference of Exponentials**. Kleine $\tau \rightarrow$ schnelle, „koinzidenzsensitive“ Reaktion; große $\tau \rightarrow$ träges Mitteln.

3 · Konkurrierende exzitatorische Populationen (WTA)

Das eigentliche WTA-Motiv der Vorlesung besteht aus **zwei exzitatorischen Populationen** z_1, z_2 , die je eine **Selbsterregung** w_{ee} haben und eine **gemeinsame inhibitorische Population** treiben. Diese misst die **kombinierte** Aktivität und gibt (praktisch instantan) eine effektive **direkte Hemmung** $w_{ei} = 1/a$ zurück. Mit $\tau = 200$ ms:

$$\tau \, dz_k/dt = -z_k + F(w_{ee} z_k + w_{ei} \cdot F(z_1+z_2) + V_k), \quad k = 1, 2$$

$$F(z) = \exp(a (z + b))$$

Wichtig: Die Konkurrenz läuft **nicht** über direkte gegenseitige Hemmung, sondern über eine **geteilte Inhibition** (shared inhibition), die beide Populationen gemeinsam dämpft.

3.1 · Phasenraum-Analyse (Nullklinen & Fixpunkte)

Man analysiert das System in der Phasenebene (z_1, z_2) : Die **Nullklinen** ($dz_1/dt = 0$ und $dz_2/dt = 0$) und ihre **Schnittpunkte = Fixpunkte** bestimmen das Verhalten. Je nach Input ergeben sich drei Regime:

Input	Fixpunkt-Struktur & Verhalten
$V_1 = V_2 = 4$ (schwach)	Drei stabile Fixpunkte. FP1 (symmetrisch, $\sim (3,3)$): beide Populationen feuern moderat und koexistieren . FP2/FP3 (Ecken): eine Population unterdrückt die andere. Welcher Fixpunkt erreicht wird, hängt vom Startzustand ab.
$ V_1 - V_2 > \delta$ (asymmetrisch)	Nur ein stabiler Fixpunkt $\rightarrow$ der stärker getriebene Kanal gewinnt fast die gesamte Aktivität. Das Netz selektiert zuverlässig den größten Input.
$V_1 = V_2 \gtrsim 4,7$ (stark, symmetrisch)	Saddle-node-Bifurkation: symmetrischer Fixpunkt und Sattelpunkt verschmelzen $\rightarrow$ schon kleinste Anfangsunterschiede entscheiden über den Gewinner.

3.2 · Winner-Takes-All & kritische Verlangsamung

Sobald Start- oder Eingangszustand **unsymmetrisch** ist, zieht das System in eine **Gewinner-Ecke**: die stärkere Population übernimmt fast die ganze Aktivität, die schwächere wird nahezu ausgeschaltet — „**Winner takes all**“.

Nahe der **Saddle-node-Bifurkation** ($V \gtrsim 4,7$) zeigt das System **kritische Verlangsamung (critical slowing down)**: Es „klebt“ lange im labilen symmetrischen Zustand ($z_1 \approx z_2 \approx 4$), bevor es **abrupt** umschaltet (ein Kanal springt hoch, der andere fällt auf ~ 0). So wirkt das WTA-Netz nahe der Bifurkation als **sensibler Entscheider** mit variabler, teils langer Reaktionszeit — ein Modell z. B. für wahrnehmungsbezogene Entscheidungen.

4 · Input-Integration mit mehreren WTA-Populationen

Erweitert man auf **viele** konkurrierende Populationen z_k , jede auf ein anderes Muster getunt ($V_k = \sum_i V_{ki} x_i$), die alle denselben Input x sehen, steht die Frage: „**Wer passt am besten?**“ Aus Tuning (§1) + WTA-Konkurrenz (§3) entsteht ein **Klassifikator** mit zwei Eigenschaften:

- **Zuverlässige Detektion** des Inputs durch Konkurrenz.
- **Eindeutiger Output-Code**: der Gewinner nimmt fast die gesamte Aktivität → Place-Code.

Jede Population misst per **Skalarprodukt**, wie gut der Input zu ihrem Muster passt; die Konkurrenz wählt den besten Treffer. Das ist die Grundidee vieler neuronaler Erkennungssysteme.

Kernbotschaften L9: Tuning = Template-Matching: $z_k = F(V_k \cdot x)$, maximale Antwort für $x \parallel V_k$. Feed-forward-Neuron = Tiefpass, Green-Funktion $G(t) = \Theta(t)e^{-t/\tau}$; zwei Filter hintereinander → Difference of Exponentials. WTA-Modell: zwei exzitatorische Populationen (Selbsterregung w_{ee}) + **gemeinsame** Inhibition $w_{ei} = 1/a$, $F(z) = \exp(a(z+b))$, $\tau = 200$ ms. Phasenraum: schwacher Input ($V=4$) → **drei** stabile Fixpunkte (symmetrisch + zwei Gewinner); asymmetrischer Input → **ein** Fixpunkt (stärkerer gewinnt); $V \geq 4,7$ → Saddle-node-Bifurkation mit **kritischer Verlangsamung**. Viele WTA-Populationen + Tuning = Klassifikator (zuverlässige Detektion + eindeutiger Place-Code).

Multiple-Choice-Fragen (Lösungen in [Loesungen_MC.pdf](#))

MC 9.1 — Ein Neuron $z_k = F(V_k \cdot x)$ reagiert bei fester Reizstärke $\|x\|$ maximal, wenn der Input ...

1. orthogonal zum Gewichtsvektor V_k steht
2. parallel zum Gewichtsvektor V_k liegt
3. minimale Norm hat
4. rein zufälliges Rauschen ist

MC 9.2 — Wie ist der Gewichtsvektor V_k zu interpretieren?

1. als Refraktärzeit des Neurons
2. als Poisson-Rate des Inputs
3. als bevorzugtes Eingangsmuster / räumlicher Kernel (Template-Matching)
4. als Membranzeitkonstante

MC 9.3 — In einem Feed-forward-Netz wirkt jedes Neuron auf seinen Input als ...

1. reiner Hochpass
2. idealer Integrator ohne Leck

3. Tiefpass mit Green-Funktion $G(t) = \Theta(t) e^{-t/\tau}$
4. NAND-Gatter

MC 9.4 — Schaltet man zwei exponentielle Tiefpassfilter hintereinander, ergibt sich als Impulsantwort ...

1. eine Sinusschwingung
2. eine lineare Rampe
3. ein reiner Dirac-Impuls
4. eine Difference of Exponentials

MC 9.5 — Wodurch konkurrieren die beiden exzitatorischen Populationen im WTA-Modell der Vorlesung?

1. über eine gemeinsame inhibitorische Population (geteilte Hemmung)
2. über elektrische Synapsen (Gap Junctions)
3. über direkte gegenseitige Erregung
4. gar nicht — sie sind unabhängig

MC 9.6 — Bei **schwachem, symmetrischem** Input ($V_1 = V_2 = 4$) hat das WTA-System ...

1. gar keinen Fixpunkt
2. genau einen instabilen Grenzyklus
3. drei stabile Fixpunkte (ein symmetrischer + zwei Gewinner-Fixpunkte)
4. exakt zwei Fixpunkte und sonst nichts

MC 9.7 — Bei **asymmetrischem** Input ($|V_1 - V_2| > \delta$) ...

1. feuern beide Populationen exakt gleich stark
2. gibt es einen stabilen Fixpunkt — der stärker getriebene Kanal gewinnt
3. verschwindet jede Aktivität
4. entsteht eine Poisson-Statistik

MC 9.8 — Was passiert bei $V_1 = V_2 \gtrsim 4,7$?

1. das System wird rein linear
2. Saddle-node-Bifurkation — kleinste Anfangsunterschiede entscheiden den Gewinner
3. alle Fixpunkte werden instabil und die Aktivität explodiert
4. die Zeitkonstante τ wird negativ

MC 9.9 — „Kritische Verlangsamung“ (critical slowing down) nahe der Bifurkation bedeutet ...

1. das Neuron feuert gar nicht mehr
2. die Membranzeitkonstante sinkt auf 0
3. globale Synchronisation aller Neuronen
4. das System verharrt lange im labilen symmetrischen Zustand und schaltet dann abrupt um

MC 9.10 — Kombiniert man Tuning mit mehreren konkurrierenden WTA-Populationen, entsteht ...

1. ein reines Feed-forward-Signal ohne Funktion
2. ausschließlich Poisson-Rauschen
3. ein Klassifikator: zuverlässige Detektion + eindeutiger Output-Code (Gewinner nimmt fast alle Aktivität)
4. ein idealer linearer Mittelwertbildner

Freitext-Fragen (zum Besprechen)

1. Zeige, dass ein Neuron $z_k = F(\mathbf{V}_k \cdot \mathbf{x})$ bei fester Reizstärke maximal auf $\mathbf{x} \parallel \mathbf{V}_k$ antwortet. Wieso ist die Tuning-Kurve ein Template-Matching, und was bedeutet $\mathbf{V}_k$ anschaulich?
2. Erkläre die zeitliche Dynamik in Feed-forward-Netzen: Warum ist jedes Neuron ein Tiefpass, was ist die Green'sche Funktion, und warum ergeben zwei kaskadierte Filter eine Difference of Exponentials?
3. Beschreibe das WTA-Modell der Vorlesung (zwei exzitatorische Populationen mit Selbsterregung, gemeinsame Inhibition, $F(z) = \exp(a(z+b))$). Wie liefert die Nullklinen-/Phasenraum-Analyse die Fixpunkte?
4. Vergleiche die drei Input-Regime (schwach-symmetrisch, asymmetrisch, $V \gtrsim 4,7$) hinsichtlich Zahl und Art der Fixpunkte und des resultierenden Verhaltens.
5. Was ist eine Saddle-node-Bifurkation, und was bedeutet „kritische Verlangsamung“? Warum wirkt das WTA-Netz nahe der Bifurkation als sensibler Entscheider mit variabler Reaktionszeit?
6. Wie entsteht aus Tuning (§1) und mehreren konkurrierenden WTA-Populationen ein Klassifikator? Welche zwei Eigenschaften machen ihn nützlich?