

Lösungen · Multiple-Choice (alle Vorlesungen)

Brain-Inspired Computing · Klausurvorbereitung · Lösungsschlüssel mit Begründungen

Nutze diese Datei erst **nach** dem Beantworten der Fragen — nicht vorher spicken. Die Antwortpositionen (A-D) sind bewusst gemischt.

Vorlesung 01 · Einführung, Neuron & Membran

Frage	Antwort	Begründung
1.1	A	Falsch ist: Gehirn hat Speicher & Verarbeitung <i>vermischt</i> (in-memory), nicht getrennt.
1.2	D	Pumpe erzeugt die Konzentrationsdifferenz unter ATP-Verbrauch ($\sim \frac{2}{3}$ Energie); Ladungsbeitrag vernachlässigbar.
1.3	B	$\tau_m = C_m / g_L = R_m C_m$.
1.4	C	GHK kombiniert mehrere Ionen gewichtet nach Permeabilitäten zu E_L (Nernst = ein Ion).
1.5	D	$I_X = g_X(u - E_X)$: $u < E_X \Rightarrow I < 0$.
1.6	B	Reines RC ist passiv/linear ohne regenerative spannungsabhängige Leitwerte $\rightarrow$ kein Spike.
1.7	A	Im Ruhezustand dominiert die K^+ -Permeabilität $\rightarrow E_L$ nahe E_K .
1.8	B	Patch-Clamp (einzelne Ionenkanäle): Neher & Sakmann.
1.9	A	Kleine $\tau_m \rightarrow$ schnelle Reaktion $\rightarrow$ Koinzidenzdetektor.
1.10	C	$\sim 10^{11}$ Neuronen, $\sim 10^{15}$ Synapsen, ~ 20 W.

Vorlesung 02 · Aktionspotential & Hodgkin-Huxley

Frage	Antwort	Begründung
2.1	B	

Frage	Antwort	Begründung
		$g_{Na} \propto m^3h$ (3 Aktivierungs-, 1 Inaktivierungsgate).
2.2	C	Absolute Refraktärzeit: h-Gates geschlossen (Na^+ -Inaktivierung) → gar kein Spike.
2.3	A	Keine feste Schwelle; Amplitude UND Änderungsrate zählen → Rheobase.
2.4	A	Ende der Inhibition deinaktiviert h → Na^+ verfügbar → Rebound-Spike.
2.5	B	TTX blockiert Na^+ -Kanäle; der Kommandostrom spiegelt dann I_{Na} .
2.6	B	m ist am schnellsten und dominiert den Aufstrich.
2.7	D	HH ist Typ II (Rate springt bei Onset auf endlichen Wert).
2.8	B	5 gekoppelte ODEs (u, m, h, n + Reiz).
2.9	B	Na^+ -Kanal leitet, wenn alle 3 m offen UND h offen.
2.10	B	Undershoot: n-Gates noch offen → u Richtung $E_K \approx -90$ mV.
2.11	A	Resonanz: passend beabstandete unter-schwellige Reize lösen gemeinsam einen Spike aus.

Vorlesung 03 · LIF & 2D-Modelle

Frage	Antwort	Begründung
3.1	D	Einfaches LIF hat keinen post-inhibitorischen Rebound (fehlende 2. Variable).
3.2	D	Spike-Train wirkt nicht auf die Membran zurück; Info fließt Membran → Spike.
3.3	A	m ist quasi instantan ($m \approx m_0(u)$) → 1. ODE entfällt.
3.4	C	BrainScaleS basiert auf AdEx (Naud 2008).
3.5	C	LIF ist Typ I (kontinuierlicher Anstieg ab Schwellstrom).
3.6	C	Maximale Rate durch τ_{ref} begrenzt ($v_{max} = 1/\tau_{ref}$).

Frage	Antwort	Begründung
3.7	B	Feuert nie, wenn $I/g_L + E_L$ die Schwelle ϑ nicht erreicht.
3.8	B	ω zieht u nach Spike nach unten (Adaptation) und ermöglicht Rebound.
3.9	B	Falsch ist: „LIF kann Rebound zeigen“ — kann es nicht.
3.10	C	n & h werden zu ω zusammengefasst, da $\tau_n \approx \tau_h$, $n_0 \approx 1 - h_0$.

Vorlesung 04 · Synapsen & synaptische Übertragung

Frage	Antwort	Begründung
4.1	A	Ca^{2+} -Einstrom durch spannungsgesteuerte Kanäle löst Vesikelfusion aus.
4.2	D	$E_{rev} \approx -70 \text{ mV (Cl}^-) \rightarrow$ inhibitorisch (GABA _A).
4.3	C	NMDA leitet nur bei Glutamat UND postsyn. Depolarisation (Mg^{2+} -Block gelöst).
4.4	B	Myelin isoliert; AP springt zwischen Ranvier-Schnürringen $\rightarrow$ schneller/effizienter.
4.5	C	Gap Junctions: schnell, bidirektional, synchronisierend.
4.6	B	Erregend/hemmend entscheidet E_{syn} relativ zu Ruhe-/Schwellpotential.
4.7	A	AMPA: schnellste, häufigste exzitatorische Synapse.
4.8	C	Shunting inhibition: Hemmung durch erhöhten Leitwert, auch ohne Hyperpolarisation.
4.9	A	Vesikelfreisetzung ist stochastisch/probabilistisch.
4.10	A	NMDA: längste Zeitkonstante ($\sim 20 \text{ ms}$), leitet Ca^{2+} .
4.11	A	Dale's principle: gleicher Transmitter an allen Synapsen $\rightarrow$ Neuron einheitlich exz./inh.

Vorlesung 05 · Synapsenmodelle COBA/CUBA

Frage	Antwort	Begründung
5.1	D	COBA-Strom hängt via $g \cdot (u - E_{\text{syn}})$ vom Membranpotential ab, CUBA nicht.
5.2	A	$\tau_{\text{eff}} = C/g_{\text{eff}}$ sinkt, da $g_{\text{eff}} = g_L + \Sigma g_k$ steigt.
5.3	B	Alpha = Grenzfall der Difference-of-Exponentials ($\tau_r \rightarrow \tau_d$).
5.4	B	HCS: hoher Leitwert, kurzes τ_{eff} , fluktuierendes Potential; COBA-Modell.
5.5	C	Nahe E_{exc} wird die Triebkraft ($u - E_{\text{exc}}$) klein $\rightarrow$ kleiner Strom.
5.6	C	Single-exp Kernel: sprunghafter Anstieg, exponentieller Abfall.
5.7	C	CUBA-Gefahr: unphysikalisch weite Depolarisation (kein Reversal begrenzt den Strom).
5.8	C	Im HCS wird das Neuron ein schneller Koinzidenzdetektor.
5.9	B	Difference-of-Exp hat eine endliche Anstiegszeit (ggü. single-exp).
5.10	B	CUBA: PSPs stets gleich groß; $\tau_{\text{eff}} = \tau_m$.

Vorlesung 06 · Statistik von Spike-Trains

Frage	Antwort	Begründung
6.1	B	Poisson: $\langle N \rangle = \text{Var}(N) = \nu T \rightarrow \text{Fano} = 1$.
6.2	B	ISI exponentiell: $\nu e^{-\nu s}$.
6.3	B	Refraktärzeit $\rightarrow$ regelmäßiger $\rightarrow C_V < 1$.
6.4	C	Fano-Faktor = $\text{Var}(N)/\langle N \rangle$; $\approx 1 \rightarrow$ Poisson-artig.
6.5	C	PSTH: Trial-gemittelte Rate, am Stimulus-Onset ausgerichtet.
6.6	B	Memoryless: Spike-Wahrscheinlichkeit unabhängig von der Vergangenheit.
6.7	D	$C_V = \sigma_{\text{ISI}} / \langle \text{ISI} \rangle$.
6.8	A	

Frage	Antwort	Begründung
		$C_V \approx 0 \rightarrow$ nahezu periodisch/sehr regelmäßig.
6.9	B	Binomial $\rightarrow$ Poisson: Produkt $M \cdot p = \nu T$ konstant halten.
6.10	B	Exp-ISI-Verteilung: Maximum bei $s = 0$ (kurze ISIs am wahrscheinlichsten).
6.11	C	Top-down = Black-Box-Charakterisierung aus Messungen (biophysik-agnostisch), vs. Bottom-up (Biophysik).

Vorlesung 07 · Korrelation, Renewal, PSD & STA

Frage	Antwort	Begründung
7.1	D	Fortlaufende Signale haben unendliche Energie $\rightarrow$ Zeitmittel $(1/2T)f$ macht das Integral konvergent.
7.2	C	PSD = Fourier-Transformierte der Autokorrelationsfunktion (stationär).
7.3	A	Renewal: Gedächtnis bis zum jüngsten Ereignis (LIF-Reset).
7.4	D	STA = mittlerer Reiz im Fenster vor jedem Spike $\rightarrow$ lineares rezeptives Feld.
7.5	B	$m(\tau)$ = Renewal-Dichte: bedingte Dichte eines Folgespikes τ nach Referenzspike.
7.6	C	ACF ist symmetrisch: $C_{ii}(s) = C_{ii}(-s)$.
7.7	D	$\nu \delta(\tau)$: jeder Spike korreliert bei $\tau=0$ perfekt mit sich selbst.
7.8	D	Reset löscht die Vergangenheit $\rightarrow$ aufeinanderfolgende ISIs unabhängig $\rightarrow$ Renewal.
7.9	A	STA ist ein lineares Maß $\rightarrow$ stark nichtlineare Antworten nur unvollständig erfasst.
7.10	B	Aus der ISI-Verteilung $P_{ISI}(\tau)$ folgt via Wiener-Chintschin die PSD.
7.11	C	White Noise enthält alle Frequenzen gleich $\rightarrow$ unverzerrte STA (hängt sonst von der Reizstatistik ab).

Vorlesung 08 · Neuronale Codes & Netze

Frage	Antwort	Begründung
8.1	B	Place-Code nutzt die Identität des feuernden Neurons (Ortszellen).
8.2	D	On-Center-Felder → Difference of Gaussians (DoG).
8.3	A	Kleines Rate-Netz realisiert NAND; NAND funktional vollständig → Turing-vollständig.
8.4	A	Delay-Line + Koinzidenzdetektor = Temporal-Code (μ s-Präzision).
8.5	C	$v_{\text{out}} = F(\sum_j w_j v_j)$: Brücke zu Perzeptron/Deep Learning.
8.6	D	$\text{NOT}(x) = \text{NAND}(x, x)$.
8.7	C	Diffuses Licht: erregendes Zentrum und hemmendes Umfeld heben sich auf.
8.8	D	Temporal-Code hat die höchste zeitliche Auflösung.
8.9	C	Phase Precession = Phase-Code (relativ zur Theta-Oszillation).
8.10	B	Rule-based ist möglich (Turing-vollständig), aber nicht der natürliche/effiziente Modus.
8.11	B	$\text{NOT} = 1$ Neuron (Gewicht -1 , Bias $H+L$); $\text{NAND} =$ zweistufiges Netz (Nichtlinearität an z_1).
8.12	A	Rekurrentes Rate-Netz: $F =$ Aktivierungsfunktion, $b_k =$ Bias, mit Rückkopplung $w_{kj} z_j$.

Vorlesung 09 · Tuning, Netzdynamik & WTA

Frage	Antwort	Begründung
9.1	B	Skalarprodukt $\mathbf{V}_k \cdot \mathbf{x}$ maximal, wenn Input parallel zu $\mathbf{V}_k$ (bei fester $\ \mathbf{x}\ $).
9.2	C	$\mathbf{V}_k =$ bevorzugtes Eingangsmuster / räumlicher Kernel → Template-Matching.
9.3	C	Feed-forward-Neuron = Tiefpass, Green-Funktion $G(t) = \Theta(t)e^{-t/\tau}$.

Frage	Antwort	Begründung
9.4	D	Zwei kaskadierte Exponential-Tiefpässe → Difference of Exponentials.
9.5	A	Konkurrenz über eine gemeinsame inhibitorische Population (geteilte Hemmung).
9.6	C	Schwacher symmetrischer Input ($V=4$) → drei stabile Fixpunkte (symmetrisch + zwei Gewinner).
9.7	B	Asymmetrischer Input ($ V_1 - V_2 > \delta$) → ein Fixpunkt, stärkerer Kanal gewinnt.
9.8	B	$V \gtrsim 4,7$ → Saddle-node-Bifurkation; kleinste Anfangsunterschiede entscheiden.
9.9	D	Critical slowing down: langes Verharren im labilen Zustand, dann abrupte Umschaltung.
9.10	C	Tuning + mehrere WTA-Populationen = Klassifikator (Detektion + eindeutiger Output-Code).

Vorlesung 10 · Plastizität: STP, LTP/LTD, STDP

Frage	Antwort	Begründung
10.1	D	Tsodyks-Markram: $R + E + I = 1$.
10.2	A	Depression: R zwischen Spikes nicht erholt (hohe Rate) → kleinere PSPs.
10.3	C	pre vor post ($\Delta t > 0$) → LTP.
10.4	D	NMDAR = Koinzidenzdetektor (Glutamat + Depol.), steuert Ca^{2+} -Einstrom.
10.5	A	LTP und LTD über (teils) verschiedene biochemische Pfade.
10.6	C	Facilitation: adaptiver, mit jedem Spike steigender Freisetzungsparameter $U(t)$.
10.7	D	Hochfrequente Stimulation (~ 100 Hz) → LTP.
10.8	C	Hohe $[\text{Ca}^{2+}]$ → LTP, moderate $[\text{Ca}^{2+}]$ → LTD.
10.9	B	Postsyn. Timing-Signal via rückwärtslaufende AP (bAP).
10.10	B	Hebb: A kausal am Feuern von B beteiligt → Verbindung $A \rightarrow B$ verstärkt.

Frage	Antwort	Begründung
10.11	B	STDP hat verschiedene Formen, ist nichtlinear/orts-/frequenzabhängig → nicht universell.
10.12	C	Speicher-Argument: $\sim 10^{15}$ Synapsen $\gg \sim 10^{10}$ Basenpaare (≈ 2 GB) → nicht genetisch kodierbar.

Vorlesung 11 · Neuromorphe Hardware & BrainScaleS

Frage	Antwort	Begründung
11.1	A	Flaschenhals = ständiger Datentransport zwischen getrenntem Speicher und CPU.
11.2	C	Physikalisches Modell: Parameter = physikalische Größen; die Schaltung ist das Modell.
11.3	B	BrainScaleS setzt AdEx um.
11.4	C	BrainScaleS ist analog und stark beschleunigt (~ 1000 – $10\,000\times$); andere digital.
11.5	A	Hybrid Plasticity: analoge Korrelationsmessung + digitale PPU.
11.6	D	Zwei Klassen: Deep Learning (Backprop) vs. lokale Plastizität (Biologie).
11.7	B	In-Memory: Gewichte lokal am Rechenort (MAC an der Synapse), keine Trennung.
11.8	D	$\sim 10^6$ aus viel höherer Spannungsänderungsrate (V/s) kleiner VLSI-Bauelemente.
11.9	C	Spike-Netze trainierbar via Surrogate Gradients / Backprop-through-time.
11.10	C	Loihi: digital, LIF, programmierbares lokales Lernen, nicht Echtzeit.
11.11	C	Lokale Plastizitätsregeln justieren Parameter selbst („Lernen ersetzt Kalibrieren“).
11.12	D	PPU = digitale SIMD-Einheit, führt Plastizitätsregeln über Gewichte/Struktur/Raten aus.